

---

# 基于多维时空气象数据融合的风光互补发电功率波动预测研究

张渊明

**摘要：**区域多维气象信息对于风光互补发电系统的输出功率波动具有重要影响，提高对于多维时空气象信息的利用效率以提高对于风光系统输出功率波动的预测效果对于电力系统的安全稳定运行具有重要意义。针对该问题，文中研究了基于多维时空气象数据融合的风光功率波动预测方法。所述方法首先通过图卷积神经网络对区域多测量点的多维空间气象信息数据进行融合并提取功率波动相关空间特征，然后在此基础上利用含多头注意力机制的长短时序记忆网络对相关时序数据进行融合，以进一步提取功率波动相关的时序信息特征，进而利用相关时空特征实现对风光互补发电系统功率波动的预测。实验结果表明，所述方法具有较好的平均误差、均方根误差和平均绝对百分比等性能指标，平均误差相对于对比方法分别提高约 77.9%、73.2%、67.9%、68.7%和 48.0%，均方根误差相对于对比方法分别提高约 77.9%、68.3%、62.4%、64.8%和 50.0%，平均绝对百分比相对于对比方法分别提高约 61.6%、59.0%、50.8%、54.6%和 33.1%，具有较好的风光互补发电系统输出功率波动预测效果。

**关键词：**时空气象数据；风光系统；数据融合；预测

**中图分类号：**TM933

**文献标识码：**B

## Research on power fluctuation prediction of wind-solar complementary system based on multidimensional spatiotemporal meteorological data

**Abstract:** Regional multi-dimensional meteorological information has a significant impact on the output power fluctuations of wind-solar complementary systems. Improving the utilization efficiency of multidimensional spatiotemporal meteorological information to enhance the prediction of the output power fluctuations is of great significance for the safe and stable operation of power systems. In response to this issue, the article studied a wind-solar power fluctuation prediction method based on multidimensional spatiotemporal meteorological data fusion. First, graph convolutional neural network is used to fuse multidimensional spatial meteorological data from several measurement points and extract fluctuation-related spatial features. Then, a long short-time memory network with multi-head attention mechanism is used to fuse the time series data to further extract temporal fluctuation-related information features. Finally, the extracted features are utilized to predict the power fluctuation. Experimental results show that the proposed method has good performance indicators such as MAE, RMSE and MAPE, where MAE is increased by about 77.9%, 73.2%, 67.9%, 68.7%, and 48.0%, RMSE is increased by about 77.9%, 68.3%, 62.4%, 64.8%, and 50.0%, and MAPE is increased by about 61.6%, 59.0%, 50.8%, 54.6%, and 33.1% compared to the comparison method, respectively. It demonstrates the proposed method has a good predictive effect on output power fluctuations of wind-solar complementary generation system.

**Keywords:** spatiotemporal meteorological data, wind-solar complementary system, data fusion, prediction

## 0 引言

随着我国双碳目标的不断推进和新型电力系统建设的不断发展,分布式风光发电接入电网的比例逐年增加<sup>[1-2]</sup>。这些可再生能源的接入对于降低温室气体的排放、改善空气质量与公共健康以及实现我国的低碳可持续发展具有重要意义。然而,大量分布式可再生能源的接入也为电力系统的运行带来了挑战,一方面,风光电力的不确定性、间歇性和波动性成为电力系统中的发电不可控因素,对电网的供电安全和稳定性造成影响,导致电网供求关系失配以及电压波动、频率偏差等问题<sup>[3]</sup>;另一方面,风光电力波动所带来的电能质量问题在挑战电网运行控制稳定性的同时也降低了用户的用电体验<sup>[4]</sup>。由于风光电力存在时空互补特性,采用风光互补发电能够在一定程度上缓解上述问题,然而由于风光电力各自固有的随机性,仍是当前电网运行的重要挑战。因此,在电力系统运行过程中提高对风光互补电力波动的预测能力对于保障电力系统的安全、稳定运行以及用户用电的稳定、可靠具有重要意义<sup>[5-6]</sup>。

当前针对风光及两者互补发电的预测已有较多研究并取得了许多重要成果。传统的功率预测多基于两者的统计学模型,如文献[7]利用差分自回归整合移动平均模型对风光荷进行组合预测,以提高能源系统边缘计算的服务和管理能力;文献[8]采用Beta分布对风电输出功率进行建模,用于降低风电功率的预测误差;文献[9]提出了基于Copula函数的马尔科夫链风速预测模型,用于提高对短期风电功率的预测能力以降低随机波动对电网运行稳定性的影响。当前随着计算机系统性能的提升和机器学习技术的快速发展,以神经网络为基础的深度学习技术成为研究的热点,通过深度学习模型对历史发电进行拟合以提高风光等电力的预测效率,如文献[10]采用自适应樽海鞘算法对风光互补并网发电的BP神经网络功率预测模型进行优化,以解决模型易避免预测模型陷入局部最优从而提高预测精度;文献[11]采用基于神经网络的分布式模型预测控制方法解决风光互补发电系统中的地理隔离和通讯缺失问题;文献[12]针对风光功率预测时的气象因素不全面问题,提出了结合经验模态分解和长短期记忆网络的风光功率短期预测方法;文献[13]结合传统的差分自回归移动平均模型和长短期记忆网络模型对风光综合发电进行预测,以提高模型的适应性和预测精度。此外,常见基于深度学习的相关风光功率预测模型还有CEEMD-GA-BP神经网络功率预测模型<sup>[14]</sup>、二分K均值聚类-BP神经网络功率预测模型<sup>[15]</sup>和GRU-CNN功率预测模型<sup>[16]</sup>等。

相比于传统以概率分布统计模型为主的功率预测模型,深度学习类预测模型能够更好的利用历史风光输出功率数据并从中挖掘功率序列的特征用于后续运行的预测,但上述研究中仍存在以下不足及可改进之处:传统方法多关注风光输出功率序列本质,较少结合相关气象因素,如文献[7]-[9]等基于统计分布模型的方法,同时,风光输出功率受区域气象信息影响较大,传统方法较少融合区域多源多维气象因素对风光功率进行预测,如文献[10]-[12]等均以风光输出功率序列本身为主要研究对象。此外,上述各类方法多针对风光系统自身的输出功率进行预测,较少通过预测互补系统的功率波动以反映整体的运行状态。因此,针对上述问题,文中通过融合区域多源多维时空气象数据对风光互补发电的功率波动进行预测,在空间维度通过图卷积神经网络(Graph Convolutional Networks, GCN)融合区域多节点的多维气象数据并提取功率波动相关特征,然后进一步在时间维度通过含多头注意力机制的长短时序记忆网络(Multi-head Long Short-term Memory, MHLSTM)进行功率波动相关时序特征的提取,并最终实现对风光互补系统功率波动的有效预测。

## 1 系统总体结构

文中所述基于多维时空气象数据融合的风光互补发电功率波动预测流程如图1所示,主要包括多区域多维时空气象数据采集、基于GCN的多维多区域气象数据融合和基于MHLSTM的多维时间数据特征融合等<sup>[17-19]</sup>,系统的工作流程如下:

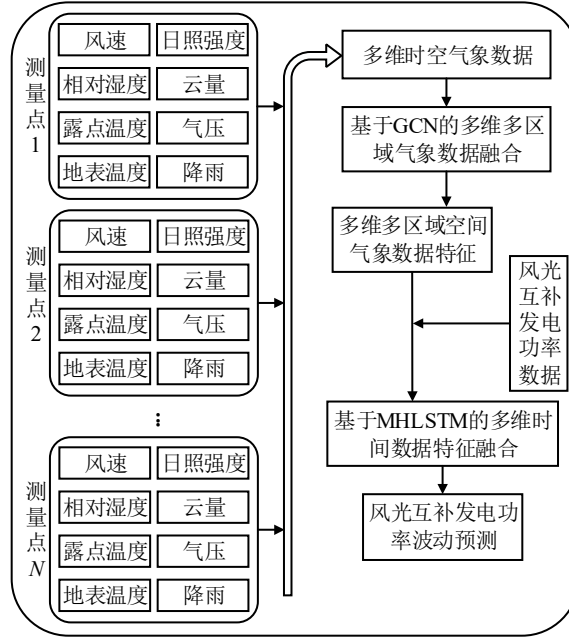


图 1 基于多维时空气象数据融合的风光互补发电功率波动预测流程

Fig.1 Flowchart of power fluctuation prediction of wind-solar complementary system based on multi-dimension spatiotemporal meteorological data

首先，采集位于风光互补发电系统周边区域  $N$  个测量点的风速、日照强度、相对湿度、云量、露点温度、气压、地表温度和降雨等风光发电相关的气象信息数据。然后，在对所获取的原始气象数据进行归一化等处理后，利用图卷积神经网络对来自区域多个测量点的多维时空气象数据进行空间特征的融合和提取，从而获取与目标点风光功率波动相关的多维空间气象特征。在此基础上，结合风光互补发电系统的输出功率数据，在时间维度上利用含多头注意力机制的长短时序记忆网络，从历史多维时空气象数据特征和风光互补输出功率数据中进一步提取与风光输出功率波动相关的时序特征，最终用于风光互补发电功率波动的预测。该系统通过融合多区域多维时空风光发电相关气象数据，实现对目标风光互补发电系统输出功率波动的有效预测，进而相关系统的安全稳定运行和运维等提供支持和保障。

## 2 基于时空气象数据融合的风光功率波动预测

### 2.1 基于 GCN 的空间数据融合特征提取

图卷积神经网络 GCN<sup>[20-21]</sup>是一种融合卷积计算和前馈神经网络的深度神经网络结构，能够对复杂的图形结构数据进行表征学习，如知识图谱、交通网络和社交网络等。GCN 能够对图结构使用卷积运算，通过对每个节点及其邻居节点的信息进行聚合和转换以学习多个节点的特征，因此能够提取图结构数据的空间特征。针对文中区域多个监测点的多维气象信息，采用图神经网络中的空间卷积网络（Spatial Graph Convolutional Networks, SGCN）进行多维时空气象信息的空间特征融合，以实现针对目标风光发电系统输出功率相关的气象信息的特征表征和提取。该基于 GCN 神经网络的空间多维气象数据融合特征提取过程如图 2 所示。

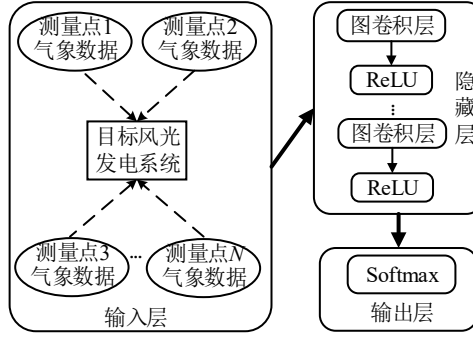


图 2 基于图卷积神经网络的多维空间气象特征提取

Fig.2 Feature extraction of multi-dimension spatial meteorological data based on GCN

图2中SGCN网络主要由输入层、隐藏层和输出层组成。其中输入层为与目标风光发电系统相关的区域多测量点的多维气象数据所构成的图数据。隐藏层包含多层图卷积操作，逐层对输入的节点信息进行卷积操作，通过各个节点的特征信息聚合和组合实现风光发电波动相关的空间特征信息的提取，并通过非线性激活函数ReLU对所提取的特征进行激活以增加模型的非线性拟合能力。其中，由于文中研究目标基于平原地区的气象特征，因此，邻接矩阵主要以各测量点与目标系统的实际地理空间距离为依据进行构建。输出层则使用Softmax 函数对所提取的特征进行映射为输出。其中，隐藏层的空间特征传播过程如式（1），

$$H^{l+1} = \sigma(G^{-1/2} A' G^{-1/2} H^l W^l) \quad (1)$$

其中， $H^{l+1}$ 和 $H^l$ 分别表示第 $l+1$ 层和第 $l$ 层提取的图特征； $A'$ 表示图的邻接矩阵与单位矩阵之和； $G$ 表示 $A'$ 的度矩阵； $W^l$ 分别表示第 $l$ 层的权重矩阵； $\sigma$ 表示ReLU激活函数，计算方式如式（2），

$$\sigma = f(x) = \max(0, x) \quad (2)$$

其中， $x$ 表示 $\sigma$ 函数的输入。

通过上述SGCN空间卷积网络，可对与目标风光发电系统相关的区域多测量点气象数据进行融合，并对风光功率波动相关的气象数据特征进行提取。所得到的空间多维气象数据特征与时序风光功率互补发电数据相结合作为后续MHLSTM的输入，进一步进行功率波动相关时序数据的特征提取，为风光互补发电系统功率波动预测提供支持。

## 2.2 基于 MHLSTM 的时间数据融合特征提取

长短时序记忆网络LSTM是一种基于门控机制控制输入时序信息流的时间循环神经网络<sup>[22-23]</sup>，由于LSTM中的门控机制能够选择性地记忆和遗忘所输入的时序信息，因此能够更有效地处理目标序列中存在的长期依赖关系，并能有效降低循环神经网络中存在的梯度爆炸和梯度消失问题的影响。而多头注意力是一种在深度神经网络模型中广泛采用的注意力机制扩展形式，它通过并行地运行多个独立的注意力机制来获取输入序列的不同子空间的注意力分布<sup>[24]</sup>，从而更全面地捕获序列中潜在的目标关联特征。通过前文SGCN网络提取了与目标风光发电系统相关的多测量点空间气象数据特征，这些融合的空间气象数据与目标点的风光输出功率波动紧密相关，通过进一步结合风光输出功率波动时序数据，能够在时空层面充分反映风光互补发电系统的运行特点。

为了进一步提高长短时序记忆网络对上述时序数据的特征提取能力，文中通过结合长短时序记忆网络和多头注意力机制对所提取的空间多维气象数据特征和风光功率波动序列进行时序融合，以更加有效的在时空综合维度实现对系统功率波动的预测，所述基于含多头注意力机制长短时序记忆网络的时间维度数据融合和风光互补发电系统功率预测流程如图3所示。

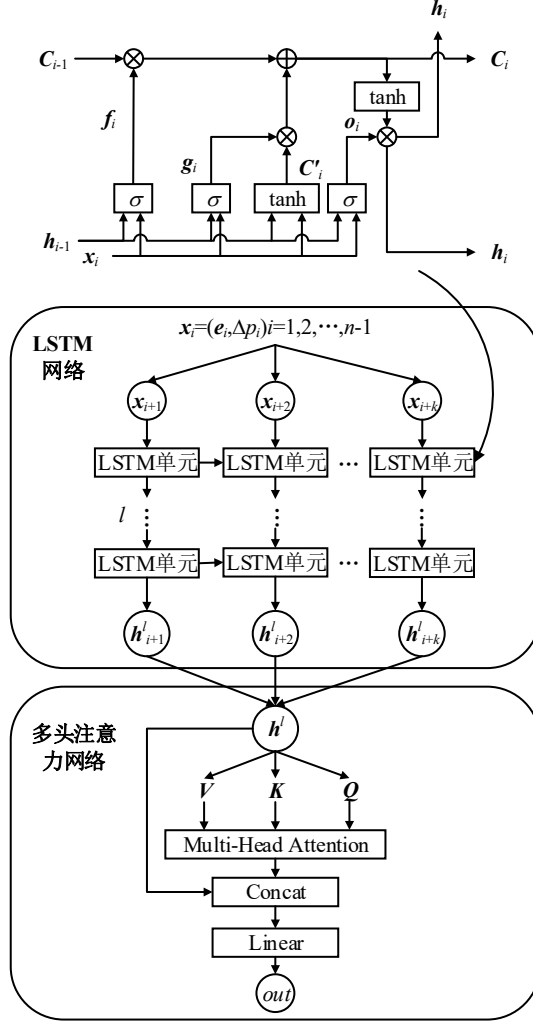


图3 基于多头注意力长短时序记忆网络的时间特征提取

Fig 3. Feature extraction of multi-dimension temporal meteorological data based on MHLSTM

图3中LSTM网络的输入 $\mathbf{x}$ 由GCN网络的输出空间气象因素特征 $\mathbf{e}$ 和风光互补系统的功率波动 $\Delta p$ 组成,下标 $i$ 表示时间序列编号,  $\Delta p$ 通过如下时间差分计算得到,

$$\Delta p_i = p_i - p_{i-1} \quad (3)$$

其中,  $p_i$ 和 $p_{i-1}$ 分别为时刻 $i$ 和 $i-1$ 的系统输出功率。

$k$ 个时段的输入序列 $\mathbf{x}_{i+1}, \mathbf{x}_{i+2}, \dots, \mathbf{x}_{i+k}$ 作为LSTM网络的输入, 经过 $l$ 层LSTM单元处理后, 得到输出时序特征 $\mathbf{h}'_{i+1}, \mathbf{h}'_{i+2}, \dots, \mathbf{h}'_{i+k}$ , LSTM单元主要由如下的遗忘门、输入门和状态判断单元组成, 通过对时序信息的选择性通过和阻塞进行特征提取, 遗忘门的处理过程为,

$$\mathbf{f}_i = \sigma(\mathbf{w}_f \mathbf{x}_i + \mathbf{u}_f \mathbf{h}_{i-1} + \mathbf{b}_f) \quad (4)$$

其中,  $\mathbf{f}_i$ 表示 $i$ 时刻的输出;  $\sigma$ 表示sigmoid激活函数;  $\mathbf{w}_f$ 和 $\mathbf{u}_f$ 分别表示 $i$ 时刻输入状态 $\mathbf{x}_i$ 和 $i-1$ 时刻的输出 $\mathbf{h}_{i-1}$ 的权重;  $\mathbf{b}_f$ 表示偏置。输入门的处理过程为,

$$\begin{cases} \mathbf{g}_i = \sigma(\mathbf{w}_g \mathbf{x}_i + \mathbf{u}_g \mathbf{h}_{i-1} + \mathbf{b}_g) \\ \mathbf{C}'_i = \tanh(\mathbf{w}_a \mathbf{x}_i + \mathbf{u}_a \mathbf{h}_{i-1} + \mathbf{b}_a) \end{cases} \quad (5)$$

其中,  $g_i$ 表示输入门的输出;  $w_g$ 和 $u_g$ 分别表示 $i$ 时刻输入状态 $x_i$ 和 $i-1$ 时刻的输出 $h_{i-1}$ 的权重;  $b_g$ 表示偏置;  $C_i$ 表示更新的状态;  $w_a$ 、 $u_a$ 和 $b_a$ 表示权重和偏置。LSTM单元输出的处理过程主要通过如下Hadamard积运算进行,

$$\begin{cases} C_i = C_{i-1} \circ f_i + g_i \circ C'_i \\ h_i = o_i \circ \tanh(C_i) \\ o_i = \sigma(w_o x_i + u_o h_{i-1} + b_o) \end{cases} \quad (6)$$

其中,  $C_i$ 和 $h_i$ 分别表示更新的状态和隐层的输出,  $f_i$ 和 $g_i$ 的作用分别是进行信息流的阻塞和更新;  $o_i$ 的作用为决定最终输出状态,  $w_o$ 、 $u_o$ 和 $b_o$ 分别表示权重和偏置; 运算符 $\circ$ 表示Hadamard积计算。

LSTM网络第 $l$ 层的输出时序特征 $h^l=(h^l_{i+1}, h^l_{i+2}, \dots, h^l_{i+k})$ 作为多头注意力网络的输入, 多头注意力网络是基于自注意力机制的并行注意力计算结构, 自注意力是一种针对单个序列不同位置通过动态权重分配捕捉序列内部关联的深度学习机制, 自注意力主要通过关键参数 $k$ 、 $v$ 和 $q$ 实现对序列特征的组合和提取,  $k$ 、 $v$ 和 $q$ 是针对输出时序的线性变换, 针对LSTM网络最终的隐层输出 $h^l$ , 其自注意力的计算过程如下,

$$\begin{cases} A(q, k, v) = \text{soft max}(AS)v \\ AS = \frac{qk^T}{\sqrt{d_k}} \end{cases} \quad (7)$$

其中,  $A(q, k, v)$ 和 $AS$ 分别表示加权求和输出和注意力得分权重;  $d_k$ 表示缩放因子, 用于稳定梯度以防止在深度网络传播中不稳定;  $q = h^l W_q$ 、 $k = h^l W_k$ 及 $v = h^l W_v$ 分别表示输入 $h^l$ 的线性变换。多头注意力在上述计算的基础上采用并行处理的方式以更全面地捕获序列 $h^l$ 中潜在功率波动时序关联因素, 计算方式为,

$$MA(Q, K, V) = \text{Concat}(h^l) W_{MA} \quad (8)$$

其中,  $MA$ 表示多头注意力输出;  $\text{Concat}$ 表示合并操作;  $W_{MA}$ 表示多头注意力权重矩阵。类似于子注意力结构, 多头注意力中将 $h^l$ 首先通过三类不同的线性变换分别得到 $Q$ 、 $K$ 和 $V$ , 然后对每个头进行类似的缩放点注意力运算, 最后, 所有头的输出拼接后通过一个线性层进行融合得到最终的输出, 该输出值即为功率波动的预测值。利用历史多维时空气象数据和风光互补发电功率数据对上述GCN网络和MHLSTM网络进行训练即可得到功率波动预测的推理模型, 进而用于对风光互补发电系统的功率波动进行预测。

### 3 实验结果

#### 3.1 实验参数设置

针对前述基于多维时空气象数据融合的风光输出功率波动预测方法的效果, 文中通过计算机仿真实验的方式进行验证。实验中所采用的计算机平台主要参数为: 系统环境 Ubuntu 22.04, CPU AMD7600X 4.7GHz, RAM DDR4 32GB 3200MHz, GPU RTX 3060 12GB, 软件环境 Python 3.7, GCN 模型和 MHLSTM 模型使用 pytorch 搭建和训练, torch 和 CUDA 版本分别为 1.12.0 和 cu116。所用实验数据来源于某风光互补电站的约 1 年的历史功率输出数据及其所在区域 6 个气象监测站的历史气象数据, 风光互补输出功率数时间间隔为 15 min, 约 35000 条, 考虑到跨季节等长时气象因素的影响, 不对相关数据进行季节等的划分, 按照时间先后将前 70%的数据作为训练集, 后 30%的数据作为测试集。实验过程中所用模型的主要参数如表 1 所示, 表中  $l_1$  和  $l_2$  分别表示 GCN 和 LSTM 的隐层数目,  $n$  和  $n_{MH}$  分别表示 GCN 的输入节点数目和头数,  $ag$  和  $f_o$  分别表示 GCN 的聚合函数和输出特征维度,  $k$  表示 LSTM 网络的输出维度,  $\text{dropout}_1$  和  $\text{dropout}_2$  分别表示 GCN 网络和 LSTM 网络的参数舍弃率,  $lr$ 、 $\text{epoch}$  和  $\text{optim}$  分别表示学习率、训练周期和优化器。上述实验参数的设置主要基于相关模型的经验参数和对文中数据进行预训练和微调得到<sup>[25]</sup>, 并非理论意义下的最优设置。

表 1 模型主要参数

Tab.1 Main parameters of the proposed model

参数	取值
$l_1$	5
$n$	6
ag	mean
$f_o$	8
$l_2$	3
$k$	10
dropout <sub>1</sub>	0
dropout <sub>2</sub>	0
$n_{MH}$	8
lr	0.002
epoch	500
optim	SGD

实验中所使用的性能评估指标为式（9）至式（11）所示的平均误差  $e_{MAE}$ 、均方根误差  $e_{RMSE}$  和平均绝对百分比  $e_{MAPE}$ ，

$$e_{MAE} = \frac{1}{T} \sum_{t=1}^T |y_{R,t} - y_{p,t}| \quad (9)$$

$$e_{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (y_{R,t} - y_{p,t})^2} \quad (10)$$

$$e_{MAPE} = \frac{1}{T} \sum_{t=1}^T \left| \frac{y_{R,t} - y_{p,t}}{y_{R,t}} \right| \cdot 100\% \quad (11)$$

其中， $y_{R,t}$  和  $y_{p,t}$  分别表示  $t$  时段风光互补发电功率波动数据的实际值和预测值， $T$  表示所有样本的时段。实验过程中为提高模型的训练效率，所有数据进行了归一化处理。

### 3.2 结果分析

图 5 所示为文中所述模型在训练过程中损失函数的变化，由图可知，在模型训练前期存在较大幅度的波动，当训练次数约为 350 次时，参数逐渐趋于收敛，损失函数的变化逐渐稳定，表明所处模型通过较少次数的训练即可实现参数收敛。




图 4 训练过程损失函数变化

Fig. 4 Loss during model training

图 5 所示为所述模型在训练结束后在训练集和测试集中对风光输出功率变化率实际值和预测值的对比。采用最终训练所得模型参数在训练集中和测试集中的 Loss 分别约为 0.025 和 0.031，表明所述预测模型具有较好的泛化性和风光功率波动预测效果。




图 5 训练集和测试集结果对比

Fig.5 Comparison of results on train set and test set

为了进一步验证所述基于多维时空气象数据融合的风光功率波动预测方法的有效性，文中对比分析了所述方法（GCN-MHLSTM）与传统的 LSTM 模型、CNN-LSTM 模型、GRU-CNN 模型、K-Means-BP 网络模型和 CEEMD-GA-BP 模型对风光互补系统输出功率波动的预测效果。对比方法中相关模型的超参数设置均采用经验设置并结合文中数据进行初步微调得到。上述几类方法的风光互补系统输出功率波动预测性能对比结果如表 6 所示。由图 6 中直观对比可知，所述 GCN-MHLSTM 方法的预测结果相对于其它对比方法更接近实际的功率波动数据，由于文中方法通过融合区域多维时空气象信息，从中提取的影响目标系统功率输出的时空气象信息特征能够更好的反映风光功率的波动特点，因此具有更好的预测效果。所述方法的平均误差  $e_{MAE}$ 、均方根误差  $e_{RMSE}$  和平均绝对百分比  $e_{MAPE}$  等性能指标如表 3 所示，由表 3 可知，文中所述 GCN-MHLSTM 方法三类性能指标均优于对比方法，其中平均误差  $e_{MAE}$  指标相对于对比方法分别提高约 77.9%、73.2%、67.9%、68.7%和 48.0%， $e_{MAPE}$  指标相对于对比方法分别提高约 77.9%、68.3%、62.4%、64.8%和 50.0%，平均绝对百分比  $e_{MAPE}$  指标相对于对比方法分别提高约 61.6%、59.0%、50.8%、54.6%和 33.1%。相较于几类对比方法，文中方法通过融合空间气象信息以提取影响风光系统输出功率波动的空间气象特征，并通过注意力机制从历史波动时序中提取影响未来功率波动的潜在特征，从而提高了对功率波动的预测效果。上述实验结果表明文中所述基于多维时空气象数据融合的风光功率波动预测方法能够有效应用于风光互补发电系统输出功率波动的综合预测，进而为相关系统的运维和安全稳定运行提供支持。






图 6 不同方法的功率波动预测效果对比

Fig.6 Comparison of prediction results using different methods for power fluctuation

表 2 不同方法的碳资产归集数据异常检测性能对比

Tab.2 Performance comparison of difference methods in anomaly detection for aggregated carbon assets data

方法	性能指标		
	$e_{MAE}$	$e_{RMSE}$	$e_{MAPE}$
LSTM	0.117	0.145	23.2%
CNN-LSTM	0.097	0.101	21.7%
GRU-CNN	0.081	0.085	18.1%
K-Means-BP	0.083	0.091	19.6%
CEEMD-GA-BP	0.050	0.064	13.3%
GCN-MHLSTM	0.026	0.030	8.9%

#### 4 结束语

文章针对风光互补发电系统的功率波动预测问题,研究了基于多维时空气象数据融合的风光功率波动预测方法。文中首先论述了预测方法的总体结构和流程,然后分别论述了基于图卷积神经网络和含多头注意力机制长短时序记忆网络的多维空间气象信息数据融合方法,图卷积神经网络通过融合区域多节点的多维气象数据以提取功率波动相关空间特征,在此基础上,长短时序记忆网络通过融合历史时序数据并利用多头注意力机制从中进一步提取功率波动相关的时间信息特征,进而实现对风光互补发电系统功率波动的预测。实验结果表明,所述方法相对于其它传统方法的平均误差、均方根误差和平均绝对百分比等性能指标均得到了提高,具有更好的风光输出功率波动预测效果。后续研究中,可通过进一步优化所述方法的网络结构以提高模型的计算效率,同时,对相关多维时空气象数据通过聚类分析等方式以进一步优化并提高数据的利用效率,从而实现对相关数据时空特征的有效提取和使用。

#### 参 考 文 献

- [1] 李子凯,杨波,周忠堂,等.考虑高比例风电波动的多注意力 TCN 电价预测方法[J].电测与仪表,2025,62(3):138-146.

- 
- LI Zikai, YANG Bo, ZHOU Zhongtang, et al. A multi-attention TCN based electricity price forecasting method considering high proportion of wind power fluctuation[J]. *Electrical Measurement & Instrumentation*, 2025,62(3):138-146.
- [2] 陶文彪,史晓航,杨钺,等.考虑高比例分布式风光与氢储的多能系统安全响应协同[J]. *电网与清洁能源*,2025,41(1):113-122.
- TAO Wenbiao, SHI Xiaohang, YANG Cheng, et al. The Safety Response Coordination of Multi-Energy System Considering High Proportion Distributed Wind-Solar and Hydrogen Storage [J]. *Power System and Clean Energy*, 2025,41(1):113-122.
- [3] 尹元亚,潘文虎,赵文广,等.基于 CEEMDAN 和 BiLSTM-AM 的超短期风速预测方法[J]. *电测与仪表*,2024,61(9):77-84.
- YIN Yuanya, PAN Wenhui, ZHAO Wenguang, et al. Ultra-short-term wind speed prediction method based on CEEMDAN and BiLSTM-AM[J]. *Electrical Measurement & Instrumentation*, 2024, 61(9): 77-84..
- [4] 张海涛,李文娟,李雪峰,等.基于变分模态分解和时间注意力机制 TCN 网络的光伏发电功率预测[J]. *电测与仪表*,2024,61(12):156-163.
- ZHANG Haitao, LI Wenjuan, LI Xuefeng, XIE, et al. Photovoltaic power forecasting based on TPA-TCN model and variational modal decomposition[J]. *Electrical Measurement & Instrumentation*, 2024, 61(12): 156-163.
- [5] 乔倪倪,谢丽蓉,叶家豪,等.基于风速波动特性划分的短期风电功率预测[J]. *电测与仪表*,2025,62(5):98-105.
- Qiao Titang, Xie Lirong, Ye Jiahao, et al. Bing. Short-term forecast of wind power based on the division of wind speed fluctuation characteristics[J]. *Electrical Measurement & Instrumentation*, 2025, 62(5): 98-105.
- [6] 王文烨,姜飞,张新鹤,等.含规模氢能综合利用的高比例风光多能源系统低碳灵活调度[J]. *电网技术*,2024,48(1):197-206.
- WANG Wenye, JIANG Fei, ZHANG Xinhe, et al. Low-carbon and Flexible Dispatch of High-proportion Wind-photovoltaic Multi-energy System With Comprehensive Utilization of Large-scale Hydrogen Energy [J]. *Power System Technology*, 2024,48(1):197-206.
- [7] 欧阳含熠,张立梅,白牧可.基于门控循环神经网络的边缘服务中心风光荷组合预测方法[J]. *现代电力*,2024,41(1):65-71.
- OUYANG Hanyi, ZHANG Limei, BAI Muke. Combined Prediction Method for Wind-photovoltaic-load in Edge Service Center Based on ARIMA-GRU [J]. *Modern Electric Power*, 2024,41(1):65-71.
- [8] 杨宏,闫玉杰,王瑜. Beta 分布在风电预测误差模型中的适用性[J]. *电测与仪表*,2020,57(11):37-41.
- YANG Hong, YAN Yujie, WANG Yu. Applicability of Beta distribution on wind power forecast error modeling[J]. *Electrical Measurement & Instrumentation*,2020,57(11):37-41.
- [9] 张彬桥,葛苏叶,李成.基于 Copula 函数的马尔科夫链风速预测模型[J]. *智慧电力*,2021,49(11):24-3037.
- ZHANG Binqiao, GE Suye, LI Cheng. Markov Chain Wind Speed Prediction Model Based on Copula Function [J]. *Smart Power*, 2021,49(11):24-3037.
- [10] 梁恩豪,孙军伟,王延峰.基于自适应樽海鞘算法优化 BP 的风光互补并网发电功率预测[J]. *电力系统保护与控制*,2021,49(24):114-120.
- LIANG Enhao, SUN Junwei, WANG Yanfeng. Wind and solar complementary grid-connected power generation prediction based on BP optimized by a swarm intelligence algorithm [J]. *Power System Protection and Control*, 2021,49(24):114-120.
- [11] 张怡,刘洋,穆勇.风光互补发电系统的分布式模型预测控制[J]. *控制工程*,2021,28(3):501-509.
- ZHANG Yi, LIU Yang, MU Yong. Distributed Model Predictive Control of Wind-solar Hybrid Power Generation System [J]. *Control Engineering of China*, 2021,28(3):501-509.
- [12] 张宇华,时鑫洋,颜楠楠,等.逆向云灰色关联相似日的 EEMD-RL-GWO-LSTM 区域风光功率短期预测[J]. *太阳能学报*,2024,45(10):144-152.
- ZHANG Yuhua, SHI Xinyang, YAN Nannan, et al. Short-term prediction of regional wind-solar power of eemd-rl-gwo-lstm on reverse cloud grey correlation similar days [J]. *Acta Energiæ Solaris Sinica*, 2024,45(10):144-152.
- [13] 王鑫,李安桂,李扬,等.基于 ARIMA-LSTM 模型的综合能源系统负荷与风光资源预测[J]. *西安建筑科技大学学报(自然科学版)*,2022,54(5):762-769.
- WANG Xin, LI Angui, LI Yang, et al. Multivariate load prediction and wind-solar resource characteristic quantity prediction of integrated energy system based on ARIMA-LSTM model [J]. *Journal of Xi'an University of Architecture & Technology(Natural Science Edition)*, 2022,54(5):762-769.
- [14] 邹文进,郝少飞,马刚,等.基于 CEEMD-GA-BP 神经网络的风光发电功率预测[J]. *电网与清洁能源*,2022,38(3):111-118.
- ZOU Wenjin, HAO Shaofei, MA Gang, et al. Forecast of Wind and Solar Power Generation Based on CEEMD-GA-BP Neural Network [J]. *Power System and Clean Energy*, 2022,38(3):111-118.
- [15] 崔杨,陈正洪,许沛华.基于机器学习的集群式风光一体短期功率预测技术[J]. *中国电力*,2020,53(3):1-7.
- CUI Yang, CHEN Zhenghong, XU Peihua. Short-Term Power Prediction for Wind Farm and Solar Plant Clusters Based on Machine Learning Method [J]. *Electric Power*, 2020,53(3):1-7.

- 
- [16] 吴晓刚, 阎洁, 葛畅, 等. 基于改进 GRU-CNN 的风光水一体化超短期功率预测方法[J]. 中国电力, 2023, 56(9): 178-186, 205.
- WU Xiaogang, YAN Jie, GE Chang, et al. Ultra-Short-Term Power Forecasting Method for Wind-Solar-Hydro Integration Based on Improved GRU-CNN [J]. Electric Power, 2023, 56(9): 178-186, 205.
- [17] 侯慧, 万屹, 王振国, 等. 台风灾害不确定性场景下双层循环风光功率预测[J]. 电力建设, 2025, 46(3): 146-154.
- HOU Hui, WAN Yi, WANG Zhenguo, et al. Wind and Photovoltaic Generation Prediction Bi-level Model Based on Uncertainty Scenarios Under Typhoon Disaster [J]. Electric Power Construction, 2025, 46(3): 146-154.
- [18] 张宇华, 时鑫洋, 颜楠楠, 等. 逆向云灰色关联相似日的 EEMD-RL-GWO-LSTM 区域风光功率短期预测[J]. 太阳能学报, 2024, 45(10): 144-152.
- Zhang Yuhua, Shi Xinyang, Yan Nannan, et al. Short-term prediction of regional wind-solar power of eemd-rl-gwo-lstm on reverse cloud grey correlation similar days [J]. Acta Energiæ Solaris Sinica, 2024, 45(10): 144-152.
- [19] 李金鑫, 张建成. 风光储发电系统预测功率波动性优化方法[J]. 电源技术, 2013, 37(1): 62-64, 140.
- LI Jinxin, ZHANG Jiancheng. Optimization method to fluctuations of predictive power of HPWS [J]. Chinese Journal of Power Sources, 2021, 58(4): 9-16.
- [20] 张丽英, 孙海航, 孙玉发, 等. 基于图卷积神经网络的节点分类方法研究综述[J]. 计算机科学, 2024, 51(4): 95-105.
- ZHANG Liying, SUN Haihang, SUN Yufa, et al. Review of Node Classification Methods Based on Graph Convolutional Neural Networks [J]. Computer Science, 2024, 51(4): 95-105.
- [21] 谢娟英, 张建宇. 图卷积神经网络综述[J]. 陕西师范大学学报(自然科学版), 2024, 52(2): 89-101.
- XIE Juanying, ZHANG Jianyu. The review of the graph convolutional neural networks [J]. Journal of Shaanxi Normal University: Natural Science Edition, 2024, 52(2): 89-101.
- [22] 杨正盛, 刘芳. 基于 LSTM 和多头注意力的气体绝缘开关柜局部放电检测框架[J]. 河南理工大学学报(自然科学版), 2025, 44(2): 108-115.
- YANG Zhengsheng, LIU Fang. A framework of partial discharge detection for gas-insulated switchgear based on LSTM and multi-head attention [J]. Journal of Henan Polytechnic University(Natural Science), 2025, 44(2): 108-115.
- [23] 黄悦华, 张子豪, 陈庆, 等. 基于多头注意力机制的 CNN-BiLSTM 高海拔多因素输电线路可听噪声预测[J]. 高压电器, 2024, 60(12): 160-169.
- HUANG Yuehua, ZHANG Zihao, CHEN Qing, et al. Prediction of Audible Noise of CNN-BiLSTM High Altitude Multi-factor Transmission Line Based on Multi-head Attention Mechanism [J]. High Voltage Apparatus, 2024, 60(12): 160-169.
- [24] 李卫军, 刘世侠, 刘雪洋, 等. 融合 Bi-LSTM 与多头注意力的分层强化学习推理方法[J]. 计算机应用研究, 2025, 42(1): 71-77.
- Li Weijun, Liu Shixia, Liu Xueyang, et al. Hierarchical reinforcement learning knowledge reasoning method integrating Bi-LSTM and multi-head attention [J]. Application Research of Computers, 2025, 42(1): 71-77.
- [25] Gorgolis, Nikolaos, Ioannis Hatzilygeroudis, Zoltan Istenes, and Lazlo-Grad Gyenne.. Hyperparameter optimization of LSTM network models through genetic algorithm. 2019 10th International Conference on Information, Intelligence, Systems and Applications (IISA). IEEE, 2019.